BDP-insight

L2 HodgeConverter

API name: BDP-insight-L2 · whitebox MRI

Public Prototype v0.1.1

실험자·사용자 가이드

User & Experimenter Guide

API Name	BDP-insight-L2
Track	Meta-13 Debugger / BDP-insight prototype
Test Model	Qwen/Qwen2.5-0.5B-Instruct + Gemma4-4ae (R2)
Prepared	2026-05-05
Source	Qwen Dynamic Debugger 실험 로그 (Min-Su Kim) + Gemma cross-model 4 건

이 문서는 v0.1.1 공개 프로토타입의 실험자·사용자용 정리 가이드다. 악용 위험을 줄이기 위해 일부 기능(L2+L3 직접 representation/tensor 수술, residual graft, hidden-state 직접 개입)은 의도적으로 빠져 있다. 본 개정판은 Gemma4-4ae(실효 ~7B) 호환성 데이터 4 건과 Token-Surface Conversion Hypothesis 섹션을 포함한다.

This document is a user/experimenter guide for the v0.1.1 public prototype. Some capabilities (direct L2+L3 representation/tensor surgery, residual graft, deep hidden-state intervention) are intentionally omitted to reduce misuse risk. This edition adds 4 cross-model compatibility records on Gemma4-4ae (~7B effective) and a Token-Surface Conversion Hypothesis section.

⚠ 중요 주의사항 / IMPORTANT NOTICE ⚠

모델마다, 그리고 입력 언어(한국어·영어 등)에 따라 동작 결과가 달라질 수 있습니다.

같은 prompt·regex 설정이라도 모델 종류와 언어에 따라 prefix 노출 패턴이 다르므로, 본 문서의 결과를 그대로 신뢰하지 말고 사용자 환경에서 직접 실험해 보는 것을 권장합니다.

Model behavior and intervention outcomes vary BY MODEL and BY INPUT LANGUAGE (Korean, English, etc.).

Even with identical prompts and regex settings, prefix-exposure patterns differ across models and languages. Do not rely on the figures in this document — please re-run the experiments in your own environment before drawing conclusions.

■ API Hub Listing — BDP-insight-L2

BDP-insight provides a prototype HodgeConverter API (BDP-insight-L2) for controlled LLM runtime-intervention experiments.
The API routes selected token/value/symbol-level intervention requests through an externalized server kernel and returns a compact public result shape.

It is designed for:

- *HodgeConverter tutorial reproduction*
- *symbolic redirection experiments*
- *runtime intervention testing*
- *BDP-insight / Meta-13 debugger prototype analysis*

This API is not intended for bulk text processing. Claims are prototype-level and observational. It does not guarantee full control over model reasoning.
Website will be open soon.

— 한국어 번역 / Korean translation —

BDP-insight 는 통제된 LLM 런타임 개입 실험을 위한 프로토타입 HodgeConverter API(BDP-insight-L2)를 제공합니다.
이 API 는 token/value/symbol 단위의 선택된 개입 요청을 외부 서버 커널을 통해 라우팅하고, 간결한 공개 결과 구조를 반환합니다.

다음 용도로 설계되었습니다:

- HodgeConverter 튜토리얼 재현
- symbolic redirection 실험
- runtime intervention 테스트
- BDP-insight / Meta-13 debugger 프로토타입 분석

본 API 는 대량 텍스트 처리를 위한 것이 아닙니다. 모든 주장은 프로토타입 수준의 관찰적 진술이며, 모델 추론에 대한 완전한 제어를 보장하지 않습니다.
공식 웹사이트는 곧 공개될 예정입니다.

목차 / Table of Contents

- 0. 중요 주의사항 + API Hub 설명 / Important Notice + API Hub Listing
- 1. 한 문단 소개 / One-paragraph product description
- 2. 동작 원리 (Output-Prefix Intervention) / How it works
- 3. 공개·유료·미래 경계와 프라이버시 / Release boundary & privacy
- 4. Quick Start — 5 분 안에 첫 실험 / Quick Start — first experiment in 5 minutes
- 5. 실험 결과 요약 (29 개: Qwen 25 + Gemma 4) / Experiment summary (29 records)
- 6. 핵심 성공 사례 / Key success cases
- 7. 관측된 동작 분류 (6.1~6.6 + 7.1~7.4 cross-model) / Observed behavior classes
- 8. 주의사항과 한계 / Caveats and limitations
- 9. 정규식 레시피 / Regex recipes
- 10. 정적 디버거 / IRSDCE 후속 노트 / Static debugger / IRSDCE follow-up note
- 11. 모델 호환성 메모 — Gemma & Token-Surface Conversion Hypothesis / Model compatibility — Gemma & Token-Surface Conversion Hypothesis
- 12. 용어집 / Glossary
- 부록 A. 전체 실험 표 (29 rows: Qwen 25 + Gemma 4) / Appendix A — Full experiment table

1. 한 문단 소개 / 1. One-paragraph product description

BDP-insight-L2 (L2 HodgeConverter)는 런타임 출력 prefix 개입(output-prefix intervention)을 위한 동적 디버거 기능이다. 사용자 프롬프트는 변경되지 않는다. 로컬 디버거가 모델로 하여금 짧은 부분 응답을 생성하게 하고, 설정된 target_regex 가 등장하는지 감시한다. target 이 등장하면 잠시 멈추고, 부분 출력을 API Hub / Modal 서버 측 Hodge 커널로 보내 패치된 prefix 를 받아 그 자리부터 이어서 생성을 재개한다.

BDP-insight-L2 (L2 HodgeConverter) is a dynamic debugger feature for runtime output-prefix intervention. The user prompt remains unchanged. The local debugger lets the model produce a short partial output, watches for a configured target_regex, pauses when the target appears, sends the partial output to the API Hub / Modal server-side Hodge kernel, receives the patched prefix, and resumes continuation from there.

이 공개 프로토타입은 보장된 산술 교정 시스템도, 일반 reasoning 부스터도 아니다. 통제된 연구·디버깅 도구로 제시되어야 한다.

This public prototype is neither a guaranteed arithmetic-correction system nor a general reasoning booster. It must be presented as a controlled research/debugging tool.

2. 동작 원리 (Output-Prefix Intervention) / 2. How it works

2.1 동적 L2 흐름 / 2.1 Dynamic L2 flow

```
user prompt
-> model begins generation
-> partial assistant output appears
-> target_first_breakpoint checks target_regex
-> server Hodge kernel patches the target span
-> local debugger resumes from patched prefix
-> final continuation reflects the modified prefix,
   base model ability, and prompt pressure
```

2.2 prompt 재작성과의 결정적 차이 / 2.2 Decisive difference from prompt rewriting

```
prompt text unchanged   = true
output prefix mutated   = true
continuation resumes from patched prefix
```

즉, 입력 프롬프트는 절대 변하지 않고, 모델이 스스로 만들어 낸 부분 출력의 한 조각만 바뀐다. 이후 이어쓰기는 그 변형된 prefix 에서 재개된다.

In other words, the input prompt never changes; only one fragment of the model's own partial output is altered. Continuation then resumes from that mutated prefix.

3. 공개·유료·미래 경계와 프라이버시 / 3. Release boundary & privacy

Layer	What is included	What is NOT included
Free / Local	Dashboard, 로컬 debugger, static/visual inspection, 비독점 유틸리티	출력 prefix 개입 자체는 포함 안 됨 (서버 호출 필요)
Paid / API	L2 HodgeConverter — 서버 Hodge 커널을 통한 출력 prefix 개입	tensor 직접 수술, hidden-state 직접 개입, residual graft 미포함
Future Research	L2+L3 직접 representation/tensor surgery, residual-state graft, 더 깊은 hidden-state 개입	공개 v0.1.1 에는 의도적으로 빠져 있음 (악용 위험 회피)

3.1 프라이버시 안내 / 3.1 Privacy notice

- L2 HodgeConverter 는 prompt/token 관측치 또는 부분 생성 출력을 paid server kernel 로 전송할 수 있다.

  L2 HodgeConverter may transmit prompt/token observations or partial generated output to the paid server kernel.

- 비밀, 자격증명, 개인정보, 사설 데이터셋, 기밀 운영 프롬프트는 제출하지 말 것.

  Do not submit secrets, credentials, personal data, private datasets, or confidential production prompts.

- BDP 는 raw prompt 나 raw 생성 텍스트를 의도적으로 영구 저장하지 않으며, request payload 는 작업 후 폐기된다.

  BDP does not intentionally persist raw prompts or generated text; request payloads are discarded after the operation.

- 운영 로그는 request ID, timestamp, status, usage counter, 길이, 해시, plan 메타데이터로 제한된다.

  Operational logs are limited to request IDs, timestamps, status, usage counters, lengths, hashes, and plan metadata.

4. Quick Start — 5 분 안에 첫 실험 / 4. Quick Start — first experiment in 5 minutes

#	할 일 / What to do	예시 / Example	왜 / Why
1	프롬프트 입력 (수식 노출 유도 추천) Enter a prompt (formula-guided recommended)	"2 + 4 는?" / "1 + 1 을 계산하고 그 결과에 3 을 더하는 수식을 먼저 쓰고 계산해"	부분 출력에 target 이 노출되어야 패치 가능 Target must appear in partial output before it can be patched
2	auto new_word	9 (왼쪽 피연산자 변경 / left-operand change)	원본 prefix 의 target 을 바꿀 값 / value to replace the matched span
3	target_regex	(?<=\+)\s*\d+	패치할 위치를 짚는 정규식 / regex pinpointing the patch location
4	wait_tokens / continuation_tokens	16 / 32 (산술 기본 / arithmetic default)	wait 는 target 등장까지 대기, continuation 은 패치 후 이어 생성할 길이 wait = tokens to wait for the target; continuation = tokens generated after the patch
5	실행 / Run	2 + 4 = 6 → 2 + 9 = 11	target-first breakpoint 가 stale-tail 을 줄여줌 target-first breakpoint reduces stale-tail artifacts
6	결과 판정 — 5 단계 분리 평가 Decision — 5-stage separated evaluation	① target detection ② server patch ③ prefix mutation ④ continuation 영향 ⑤ 최종 정답	최종 산술만으로 평가하지 말 것 / do not evaluate only by final arithmetic

4.1 수식 노출 유도 문구 / 4.1 Formula-guiding wording

```
먼저 수식만 쓰고, 그다음 계산해.

수식부터 쓰고 계산.

Complete only the equation: ...

먼저 반드시 "5 + 2 =" 형태의 수식을 한 줄로 쓰고, 그다음 이어서 계산해.
```

4.2 흔한 실수 / 4.2 Common pitfalls

- **타겟 미노출 / target not exposed:** 결과만 출력하게 만들면 target 이 부분 출력에 안 나타남. 수식 노출 유도 사용.
  If the model emits only the answer, the target never appears in the partial output — use formula-guided wording.
- **최종 산술만 평가 / evaluating only final arithmetic:** 약한 모델은 개입 없이도 산술이 틀림. 5 단계 분리 평가.
  Weak local models can fail arithmetic even without intervention — apply the 5-stage decomposition.

- **자연어 템플릿 압력 / template pressure:** 영어 템플릿은 패치 후 피연산자 위치가 바뀔 수 있음 (A02/A03). English natural-language templates may reorder operands after patching (see A02/A03).
- **breakpoint 너무 빠름 / breakpoint too early:** wait_tokens 가 작으면 'The sum of 2'에서 잘려 의미가 깨짐. Too small a wait_tokens cuts off mid-phrase (e.g. 'The sum of 2') and breaks meaning.
- **결과 토큰 stale-tail / result-token stale tail:** target-first breakpoint 를 안 쓰면 옛 결과가 그대로 남음. Without target-first breakpoint, the old answer can persist.
- **기존 분포 충돌 / pre-existing distribution clash:** target 과 같은 값으로 new_word 를 지정하면 동일 분포 처리되어 식 순서가 뒤바뀜 (A02 가설 1). Using a new_word equal to an existing token in the distribution causes order swaps (A02, hypothesis 1).

5. 실험 결과 요약 (29 개: Qwen 25 + Gemma 4) / 5. Experiment summary (29 records)

5.1 상태별 카운트 — Qwen/Qwen2.5-0.5B-Instruct / 5.1 Status counts — Qwen/Qwen2.5-0.5B-Instruct

Status	Count	Notes
Total logged experiments (Qwen)	25	Qwen 실험 로그 전체
Success / observed influence	18	수식 prefix 와 result/operator 패치
No target / inactive	3	Target 패턴이 부분 출력에 미노출
Base / model limitation	2	개입 없이도 산술 실패
Breakpoint / tail artifact	1	Breakpoint 타이밍 이슈
Needs review	1	수동 검토 대상

5.2 카테고리 분포 / 5.2 Category split

Category	Count	Description
산술연산 (Qwen)	11	기본 산술식, 피연산자/연산자/결과 패치
중간값 변경 (Qwen)	5	다단계 계산의 중간값 패치
문장형 수학 (Qwen)	4	자연어 워드 프로블럼
추론 (Qwen)	5	조건/비교/참거짓/다단계 추론
모델 호환성 (Gemma)	4	Gemma4-4ae(~7B) 호환성. § 11 참조

5.3 Cross-model compat — Gemma4-4ae / 5.3 Cross-model compatibility — Gemma4-4ae

v0.1.1 에는 Qwen 0.5B 25 건 외에 Gemma4-4ae(실효 ~7B) 4 건의 호환성 실험이 추가되어 있다. 4 건 모두 동적 디버거 호환을 확인했고, 그중 일부는 수식 구조 자체가 재조합되는 흥미로운 케이스를 보였다. 상세 가설과 비교는 § 11 참조.

6. 핵심 성공 사례 / 6. Key success cases

EXP-A05 · 오른쪽 피연산자 변경

```
Prompt: 2 + 4 는?
auto new_word: 9
target_regex: (?<=\+)\s*\d+
wait/cont: 8 / 24

Before: 2 + 4 = 6
After : 2 + 9 = 11
```

EXP-A06 · 결과값 변경

```
Prompt: 2 + 4 는?
auto new_word: 99
target_regex: (?<==\s*)\d+
wait/cont: 16 / 24

Before: 2 + 4 = 6
After : 2 + 4 = 99
```

EXP-A07 · 연산자 변경 plus → minus

```
Prompt: 2 + 4 는?
auto new_word: -
target_regex: \+
wait/cont: 16 / 32

Before: 2 + 4 = 6
After : 2 - 4 = -2
```

EXP-A09 · formula-guided 후보

```
Prompt: 2 + 7 한 값에 9를 더하면? 수식부터 쓰고 계산
auto new_word: 14
target_regex: 9
wait/cont: 100 / 48

Before: 2 + 7 + 9 = 18
After : 2 + 7 + 14 = 23
```

EXP-B02 · 중간값 변경 / 수식부터 쓰기

```
Prompt: 1 + 1 을 계산하고, 그 결과에 3을 더하는 수식을 먼저 쓰고 계산해
auto new_word: 9
target_regex: (?<==\s*)\d+
wait/cont: 32 / 32

Before: 1 + 1 = 2 / 2 + 3 = 5
After : 1 + 1 = 9 / 계산 후, 9를 3으로 더하면 12입니다.
```

EXP-D02 · 추론 / 조건 숫자 변경 / 수식 유도

```
Prompt: 철수는 사과 2개를 가지고 있고, 영희에게 3개를 받았다. 먼저 수식만 쓰고, 그다음 계산해
auto new_word: 9
target_regex: (?<!\d)2(?=\s*\+)
wait/cont: 64 / 32

Before: 철수의 사과 수: 2 개 / 영희에게 받은 사과 수: 3 개 / 총: 5 개
After : 철수의 사과 수: 9개 (2개 + 3개) / 영희: 6개 / 결과: 9개
```

7. 관측된 동작 분류 (6.1~6.6 + 7.1~7.4 cross-model) / 7. Observed behavior classes

6.1 Clean formula-prefix success

부분 출력이 깨끗한 수식을 노출했고, HodgeConverter 가 그 토큰/값을 패치한 뒤 continuation 이 변형된 prefix 에서 재계산. 가장 좋은 데모 카테고리.

```
예: 2 + 4 = 6 → 2 + 9 = 11   /   2 + 4 = 6 → 2 - 4 = -2
```

6.2 Formula-guided continuation success

프롬프트가 '수식부터 쓰고 계산'을 요구하지 않으면 모델이 피연산자를 숨기고 결과만 출력해 target 이 안 보임. 수식 노출 유도가 필요.

```
권장 문구: 먼저 수식만 쓰고, 그다음 계산해.
```

6.3 No-target cases

부분 출력에 target 이 등장하지 않으면 HodgeConverter 는 정상적으로 아무것도 하지 않는다. 이는 서버 실패가 아니라 target 이 prefix 에 노출되지 않았다는 뜻.

```
예: '계산 결과는 7 입니다'만 출력 → '5 + 2'가 prefix 에 안 나옴
```

6.4 Base model limitation

약한 로컬 모델은 개입 없이도 산술이 틀린다. L2 를 최종 정답 정확성만으로 평가하지 말 것.

```
EXP-A11: 숫자만 답하라고 했을 때 base 가 10 을 출력 (정답 18)
```

6.5 Template pressure & token-order effects

영어 자연어 템플릿은 개입 후 표현을 재구성할 수 있음. swap/혼합 형태 발생 가능. 실패가 아닌 연구 관측.

```
예: The sum of 2 and 9 is 11.  →  The sum of 9 and 2 is 11.
```

6.6 Breakpoint timing & stale-tail effects

Target-first breakpoint 는 stale-tail 을 줄이지만, 너무 일찍 멈추면 'The sum of 2' 같은 미완성 문구만 생성됨. 패치된 prefix 가 'The sum of 9'가 되어 원래 프롬프트 압력과 섞일 수 있음.

```
예: EXP-A01 wait=3, cont=24 → '9' 단독 artifact
```

7.1 Cross-model compatibility success

HodgeConverter 경로는 Qwen 전용이 아님. partial output prefix 를 관찰할 수 있는 모델이면 어디서든 동작. Gemma4-4ae(~7B)에서 실측 확인.

```
EXP-GEMMA-01/02/04: 동일 패치 흐름이 다른 모델에서 재현
```

7.2 Structured-output intervention surface

구조화된 답변(문제 이해 / 상황 파악 / 수식 / 계산 / 답변)을 많이 생성하는 모델일수록 target_regex 가 잡힐 표면이 넓어짐. 모델 사이즈가 아니라 '명시적 중간 표현 생성 성향'이 변수.

```
Gemma4-4ae: 단계별 풀이 scaffold 자동 생성 → target 안정 감지
```

7.3 Formula-prefix structural recomposition

단순 토큰 치환을 넘어, 수정된 prefix 가 원문 문제 압력과 섞여 모델이 수식 구조 자체를 재작성하는 케이스. 일관성 회복을 위한 자체 보정으로 해석.

```
EXP-GEMMA-03: $2+3$ → $9-2$  (단순 9+3 이 아닌 9-2 로 재구성)
```

7.4 Large-model scaffold advantage

큰/지시 추종 강한 모델일수록 hidden state 단의 처리 결과를 token surface 에 명시적으로 풀어내는 경향이 강해 token-surface intervention(=Hodge L2)에 더 잘 노출됨. Token-Surface Conversion Hypothesis 참조 (§ 11).

```
Gemma 7B 단계별 scaffold vs Qwen 0.5B 단답 비교
```

8. 주의사항과 한계 / 8. Caveats and limitations

Caveat	Description	Example / mitigation
No target detected	HodgeConverter 는 모델이 부분 출력에 노출하지 않은 값을 패치할 수 없다.	B03: '계산 결과는 7 입니다'만 출력 → '+ 2' target 이 등장하지 않음.
Base model arithmetic failure	작은 로컬 모델은 개입 없이도 산술을 틀린다. 최종 정답 정확성이 유일한 성공 기준은 아님.	A11: 숫자만 답으로 10 출력. target detection 과 최종 산술을 분리 평가.
Natural-language template pressure	자연어 템플릿은 패치 후 피연산자를 재정렬하거나 원래 프롬프트 압력을 다시 끌어들일 수 있다.	A02/A03: 'sum of 9 and 2' 식의 행동을 보임.
Early breakpoint artifact	Target-first breakpoint 가 산술 구조 노출 전에 멈출 수 있다.	A01: 이른 brakpoint artifact. 수식 노출 유도 / 더 긴 wait 사용.
Stale tail / answer tail	패치 전에 옛 답이 너무 많이 생성되면 continuation 이 옛 꼬리를 그대로 보존할 수 있다.	Target-first breakpoint 사용 + wait/continuation 조정.
Current prototype limitation	v0.1.1 프로토타입. 일부 정밀도 케이스는 더 나은 context guard 또는 향후 L2+L3 결합이 필요.	실패가 아닌 연구 행동으로 문서화.

9. 정규식 레시피 / 9. Regex recipes

Goal	auto new_word	target_regex	wait	cont	Notes
Left operand simple	9	2	3-8	24-32	데모는 빠르나 자연어 템플릿에 잡힐 수 있음
Left operand before plus	9	(?<!\d)2(?=\s*\+)	8-16	24-32	더 정밀한 수식형 target
Right operand after plus	9	(?<=\+)\s*\d+	8-16	24-32	2+4 → 2+9 같은 케이스
Operator plus → minus	-	\+	16-100	32-48	기호 개입 데모
Operator plus → multiply	*	\+	16-100	32-48	기호 개입 데모
Result after equals	99	(?<==\s*)\d+	16-64	24-48	결과만 패치, 모델이 피연산자를 숨길 때 유용
Formula-guided operand	14	9	64-100	32-48	'수식부터 쓰고 계산' 스타일과 함께 사용

10. 정적 디버거 / IRSDCE 후속 노트 / 10. Static debugger / IRSDCE follow-up note

동적 디버거 실험은 향후 정적 디버거의 IRSDCE 관련 뷰와 짝지어져야 한다. 정적 뷰는 출력 prefix 개입이 hidden-state geometry, layer-wise 흐름, 토큰-조건부 trajectory 를 어떻게 바꾸는지 보여 줄 수 있다. 단, 인과 증명 그 자체가 아니라 별도의 관측성(observability) 레이어로 문서화되어야 한다.

> *These dynamic-debugger experiments should later be paired with the static debugger's IRSDCE views. The static view can illustrate how output-prefix intervention shifts hidden-state geometry, layer-wise flow, and token-conditioned trajectories. It must be documented as an observability layer, not as a causal proof in itself.*

```
Static MRI / IRSDCE View:
Layer-wise Hidden-State Geometry
Under Token-Prefix Intervention
```

11. 모델 호환성 메모 / 11. Model compatibility — Gemma & Token-Surface Conversion Hypothesis

11.1 Cross-model 호환성 노트 / 11.1 Cross-model compatibility note

공개 프로토타입의 기본 실험은 Qwen/Qwen2.5-0.5B-Instruct 를 기준으로 정리했지만, HodgeConverter 경로는 Qwen 전용이 아니다. 동적 디버거는 모델이 생성한 partial output prefix 를 관찰하고, API Hub / Modal Hodge 커널을

호출해 해당 prefix 를 수술한 뒤 continuation 을 재개한다. 따라서 런타임 훅이 생성을 관찰하고 서버를 호출할 수 있는 어떤 로컬 모델과도 호환된다.

Gemma 처럼 구조화된 답변을 많이 생성하는 모델은 '문제 이해 / 상황 파악 / 수식 / 계산 / 답변' 같은 중간 출력 표면을 더 많이 드러낸다. 이 경우 target_regex 가 감지될 기회가 늘어나고, HodgeConverter 가 생성 중간의 값이나 수식을 패치하기 쉬워진다. 다만 이것은 큰 모델이 항상 더 잘 제어된다는 뜻은 아니다. 더 구조화된 중간 텍스트가 더 넓은 intervention surface 를 제공한다는 의미다.

11.2 핵심 가설 (H1) / 11.2 Core hypothesis — Token-Surface Conversion (H1)

```
H1: 모델이 클수록 / 지시 추종이 강할수록
    hidden state 단의 처리보다 token surface 단의 변환이
    자주, 그리고 크게 일어난다.

    [기제]
    추론·계산 결과를 모델이 '문제 이해 → 상황 파악 →
    수식 → 계산 → 답변' 같은 명시적 중간 출력으로
    풀어내는 경향이 강해진다.

    [Hodge L2 와의 관계]
    L2 HodgeConverter 는 token-surface 위에서 작동한다.
    따라서 token-surface 변환이 활발한 모델일수록
    intervention 이 적용될 표면이 자연히 넓어진다.
```

주의: 이는 '모델 크기가 클수록 토큰을 많이 만든다'는 단순 관찰이 아니다. 본 가설의 초점은 '동일한 추론을 hidden state 안에서 압축적으로 끝내느냐, token surface 로 풀어 쓰느냐'는 비중 차이에 있다. 후자가 커질수록 L2 같은 token-surface 개입의 작동 표면이 넓어진다.

11.3 Gemma4-4ae(실효 ~7B) 호환성 4 건 / 11.3 Four Gemma4-4ae (~7B effective) compatibility records

ID	Sub-category	Change	Before	After	Judgment
EXP-GEMMA-01	구조화 출력 / 상자 문제	2 → 9	상자 개수: 2 개 / 수식 2 × 3 / 답 6	상자 개수: 9 개 (만약 9 개라면…)	Cross-model compat success + Structured-output surface
EXP-GEMMA-02	구조화 출력 / 추론 지속	2 → 9	(GEMMA-01 과 동일)	## 문제 분석 / 문제: 9 개의 상자에 각각 사과가 3 개씩 있다…	Cross-model compat + Formula-guided continuation success
EXP-GEMMA-03	수식 구조 재조합	2 → 9	수식 $2 + 3$ / 계산 5	수식 $9 - 2$ / 계산 7	Formula-prefix structural recomposition
EXP-GEMMA-04	자연어 풀이 scaffold	2 → 9	철수 2 개 / 받은 3 개 / 답 5 개	철수가 처음에 가지고 있던 사과: 9 개 / 영희에게 받은: 3 개	Cross-model compat + Structured-

				/ …	output surface

11.4 Qwen 0.5B vs Gemma 7B 관측 비교 / 11.4 Qwen 0.5B vs Gemma 7B — observational comparison

관측 축	Qwen 0.5B	Gemma4-4ae (~7B)
중간 출력 표면	짧고 압축적. 결과만 노출 잦음.	단계별 scaffold 명시적 출력.
target 감지 안정성	자연어+숫자 혼합 시 흔들림(EXP-D01).	scaffold 덕에 안정 감지(EXP-GEMMA-04).
intervention surface	좁음. 수식 노출 유도 거의 필수.	넓음. base 출력에서 이미 노출.
base 산술 한계	약함 (EXP-A11 에서 산술 자체 실패).	기본은 안정. 단 prefix-압력 충돌 시 식 재구성(EXP-GEMMA-03).
연구적 흥미 케이스	Token-order swap (EXP-A02).	Formula-prefix structural recomposition (EXP-GEMMA-03).
Hodge L2 작동 양상	최소 작동 검증.	Token-Surface Conversion 가설의 근거.

11.5 한 문장 결론 / 11.5 One-sentence conclusion

```
Gemma 결과는 HodgeConverter 가 특정 Qwen 용 꼼수가 아니라,
생성 중간 prefix 를 관찰할 수 있는 모델 전반에 적용 가능한
동적 디버거 구조이며, 모델이 클수록 hidden-state 보다
token-surface 단의 변환이 자주·크게 일어나는 만큼
L2 개입의 작동 표면이 자연히 넓어진다는 점을 보강한다.
```

The Gemma results reinforce that HodgeConverter is not a Qwen-specific trick but a dynamic-debugger structure applicable across any model whose mid-generation prefix is observable; and to the extent that larger / instruction-tuned models perform conversion more often at the token-surface than inside hidden state, the operative surface for L2 intervention naturally widens.

12. 용어집 / 12. Glossary

Term	Definition
Output-prefix intervention	프롬프트는 그대로 두고 모델이 생성한 부분 출력의 일부를 패치한 뒤 continuation 을 재개.
target_regex	부분 출력에서 패치할 위치를 짚는 정규식. 예: (?<=\+)\s*\d+ 는 '+' 뒤의 숫자.
auto new_word	target 에 매칭된 span 을 어떤 값으로 바꿀지 지정하는 값.
wait_tokens	target 이 부분 출력에 등장할 때까지 기다리는 최대 토큰 수.
continuation_tokens	패치 후 이어서 생성할 토큰 수.
target_first_breakpoint	target 이 등장하면 바로 멈추는 동작. stale-tail 을 줄여 줌.
stale-tail	패치 전에 이미 생성된 옛 결과가 남아 continuation 이 그것을 따라가는 현상.
partial output / generated prefix	모델이 생성 중인 응답 중 brakpoint 까지 생성된 prefix.
Hodge kernel	API Hub / Modal 서버에서 patch 를 준비하는 핵심 연산 모듈.
L2	현재 공개 단계. 출력 prefix 텍스트 단계의 개입.
L2+L3	미래 연구. 직접 representation/tensor 수술, residual graft 등 hidden-state 직접 개입.
IRSDCE	정적 디버거 분석 뷰. layer-wise hidden-state geometry 관측.
formula-guided	프롬프트가 모델이 부분 출력에 수식을 노출하도록 유도하는 패턴.
Clean formula-prefix success	부분 출력에 깨끗한 수식이 노출되어 패치가 성공하는 케이스.
No-target case	부분 출력에 target 이 안 나타나서 정상적으로 아무 일도 안 하는 케이스. 실패 아님.
Token-Surface Conversion Hypothesis	큰/지시 추종 강한 모델일수록 hidden-state 단의 처리 결과를 token surface 에 더 자주·크게 풀어내는 경향이 있다는 가설. L2 개입 표면이 넓어지는 기제.
Cross-model compatibility	HodgeConverter 경로가 특정 모델 전용이 아니라, partial output prefix 를 관찰할 수 있는 모델 전반에 적용 가능함을 가리킴. Gemma4-4ae(~7B)에서 검증됨.
Structured-output intervention surface	모델이 단계별 풀이 scaffold 를 명시적으로 출력할수록 target_regex 가 잡힐 표면이 넓어짐.
Formula-prefix structural recomposition	토큰 치환만으로 끝나지 않고, 수정된 prefix 가 원문 문제 압력과 섞여 모델이 수식 구조를 자체 재작성하는 현상. (EXP-GEMMA-03)
Large-model scaffold advantage	큰 모델이 자동 생성하는 단계별 scaffold 가 token-surface intervention 의 표면을 넓혀 주는 효과.

부록 A. 전체 실험 표 (29 rows: Qwen 25 + Gemma 4) / Appendix A — Full experiment table (29 rows)

원본 매뉴얼 § 8(Qwen)과 본 개정판 § 11(Gemma)을 통합. 각 행은 워크북의 Experiment_Log 시트(29 행) 및 Cross_Model_Compat 시트와 1:1 대응한다.

ID	Category	Change	target_regex	wait/cont	Before	After	Status
EXP-A01	산술연산 / 왼쪽 피연산자 변경	2 -> 9	2	3 / 24	2 + 9 = 11	9	Breakpoint/ tail artifact
EXP-A02	산술연산 / 영어 자연어 template 비교	2 -> 9	2	3 / 24	The sum of 2 and 9 is 11.	Clean formula-prefix success - type special	Success / observed influence
EXP-A03	산술연산 / 수식 유도	2 -> 9	2	3 / 24	The answer to 2 + 9 is 11.	The answer to 2 + 9 is 11.	No target / inactive
EXP-A04	산술연산 / 수식 유도 / 좁은 regex	2 -> 4	(?<!\d)2(?=\s*\+)	8 / 24	The answer to 2 + 9 is 11.	변경토큰 → [4The answer is 4.] / [The answer to 4 is 11.]	Success / observed influence
EXP-A05	산술연산 / 오른쪽 피연산자 변경	4 -> 9	(?<=\+)\s*\d+	8 / 24	2 + 4 = 6	2 + 9 = 11	Success / observed influence
EXP-A06	산술연산 / 결과값 변경	결과 -> 99	(?<==\s*)\d+	16 / 24	2 + 4 = 6	2 + 4 = 99	Success / observed influence
EXP-A07	산술연산 / 연산자 plus → minus	+ -> -	\+	16 / 32	2 + 4 = 6	2 - 4 = -2	Success / observed influence
EXP-A08	산술연산 / 연산자 plus → multiply	+ -> *	\+	16 / 32	—	Clean formula-prefix success	Success / observed influence
EXP-A09	산술연산 / formula-guided 성공 후보	9 -> 14	9	100 / 48	2 + 7 + 9 = 18	2 + 7 + 14 = 23	Success / observed influence
EXP-A10	산술연산 / base model 한계 확인	없음	없음	—	2 + 7 + 9 = 18	2 + 7 + 9 = 18	Success / observed influence
EXP-A11	산술연산 /	없음	없음	—	10	10	Base/model

	base model 한계 / 숫자만						limitation
EXP-B01	중간값 / 후속 계산 반영	2 -> 9	2	16 / 32	1 + 1 = 2 / 그 후 3 더하면 5	1 + 1 = 9	Needs review
EXP-B02	중간값 / 수식부터 쓰기	2 -> 9	(?<==\s*)\d+	32 / 32	1 + 1 = 2 / 2 + 3 = 5	1 + 1 = 9 / 9 + 3 = 12	Success / observed influence
EXP-B03	중간값 / 오른쪽 항목 영향	2 -> 9	(?<=\+)\s*2	32 / 32	계산 결과는 7 입니다.	호지컨버터 동작 안 함	No target / inactive
EXP-B04	중간값 / 결과값만 변경	첫 결과 -> 20	(?<==\s*)\d+	48 / 32	계산 결과는 7 입니다.	계산 결과는 9 입니다.	Success / observed influence
EXP-B03-R1	중간값 / 오른쪽 항목 / 수식 노출 유도	2 -> 9	(?<=\+)\s*2	32 / 32	5 + 2 = 7 / 7 + 4 = 11	9	Base/model limitation
EXP-C01	문장형 수학 / 연산자 변경	+ -> -	\+	100 / 32	(2 + 4) 형태 답	(2 - 1 + 3 = 6) 식 변형	Success / observed influence
EXP-C02	문장형 수학 / 확정 조건 유도	+ -> -	\+	100 / 48	최종 6	수식 부분 변형됨	Success / observed influence
EXP-C03	문장형 수학 / 오른쪽 피연산자 변경	4 -> 9	(?<=\+)\s*\d+	64 / 32	(2 + 4) × 1 = 6	사과 2 개 → 9 개 받음	Success / observed influence
EXP-C04	문장형 수학 / 결과값 변경	결과 -> 99	(?<==\s*)\d+	64 / 32	(2 + 4) × 1 = 6	계산해보면: 99	Success / observed influence
EXP-D01	추론 / 조건 숫자 변경	2 -> 9	2	32 / 32	철수의 사과는 1 개입니다.	동작 안 함	No target / inactive
EXP-D02	추론 / 조건 숫자 변경 / 수식 유도	2 -> 9	(?<!\d)2(?=\s*\+)	64 / 32	철수 2 개 + 영희 3 개 = 5 개	철수 9 개 (2+3) → 9 개	Success / observed influence
EXP-D03	추론 / 비교 조건 변경	2 -> 9	2	64 / 32	A 는 2 점, B 는 5 점 → A 높음	A 는 9 점, B 는 5 점	Success / observed influence
EXP-D04	추론 / 참거짓 조건 변경	2 -> 9	2	64 / 32	2 은 5 보다 작다	9 은 5 보다 작다	Success / observed influence
EXP-D05	추론 / 다단계 숫자 변경	2 -> 9	2	64 / 32	2 * 3 = 6	9 개	Success / observed influence
EXP-GEMMA-01	모델 호환성 / 구조화 출력 / 상자 문제	2 -> 9	2	64 / 32	상자 2 개 / 2 × 3 = 6	상자 개수: 9 개 (만약 9 개라면…)	Cross-model compat
EXP-	모델 호환성 /	2 -> 9	2	64 / 32	(GEMMA-01	## 문제 분석	Cross-

GEMMA-02	구조화 출력 / 추론 지속				과 동일)	/ 9 개의 상자에 각각 사과가 3 개씩…	model compat
EXP-GEMMA-03	모델 호환성 / 수식 구조 재조합	2 -> 9	2	64 / 32	$2 + 3$ → 5	$9 - 2$ → 7 (식 재구성)	Cross-model compat
EXP-GEMMA-04	모델 호환성 / 자연어 풀이 scaffold	2 -> 9	2	32 / 32	철수 2 개 / 받은 3 개 / 답 5 개	철수 9 개 / 받은 3 개 / …	Cross-model compat

이 문서는 BDP-insight BDP-insight-L2 (L2 HodgeConverter) v0.1.1 공개 프로토타입의 사용자/실험자 가이드입니다. 추가 문의·피드백은 BDP-insight 프로젝트 채널을 통해 부탁드립니다.

This document is the user/experimenter guide for the BDP-insight BDP-insight-L2 (L2 HodgeConverter) v0.1.1 public prototype. For questions and feedback, please use the BDP-insight project channel.